

Глубокое погружение в дипломную работу

Полный русскоязычный учебный конспект по дипломной работе
о классификации респираторных звуков с помощью глубокого обучения.

Формат документа:

интуиция -> теория -> связь с твоим проектом -> практический смысл -> вопросы для защиты

Исходный файл: THESIS_DEEP_DIVE_RU.md

PDF-сборка: THESIS_DEEP_DIVE_RU.pdf

Как читать этот документ

Этот текст задуман как главный русскоязычный учебный конспект по всей дипломной работе:

- сначала дается интуиция;
- потом дается академическое объяснение;
- потом показывается, как это связано именно с твоим проектом;
- затем объясняется, что ты должен уметь сказать на защите.

Это не просто “описание кода”. Это опорный материал, чтобы:

1. понимать, что именно ты строишь;
2. не теряться в терминах;
3. уметь объяснить теорию нормальным языком;
4. переводить практические шаги в текст диплома;
5. отвечать на вопросы комиссии не общими словами, а по существу.

1. Главная идея дипломки

1.1. Короткая формулировка

Твоя дипломная работа посвящена автоматическому анализу звуков дыхания с помощью методов глубокого обучения.

Если совсем коротко, задача звучит так:

По аудиозаписи дыхания определить, присутствуют ли в ней характерные патологические респираторные звуки, и сравнить, какие архитектуры глубокого обучения лучше справляются с этой задачей.

1.2. Что является настоящей целью

Цель работы не в том, чтобы “просто обучить нейросеть”.

Цель состоит в том, чтобы построить исследовательский AI-pipeline, который:

- принимает сырые аудиозаписи дыхания;
- преобразует их в пригодные для модели признаки;
- обучает несколько моделей;
- оценивает их честно и воспроизводимо;
- показывает, как они ошибаются;

- объясняет, почему одна архитектура лучше или хуже другой;
- в идеале дает основу для демонстрационного медицинского прототипа.

1.3. Что работа не делает

Очень важно быть честным.

Работа не создает клинический прибор, который ставит официальный диагноз. Она создает исследовательский прототип, который распознает акустические паттерны, потенциально связанные с патологией дыхательной системы.

Правильная формулировка:

Система предназначена для автоматизированной поддержки анализа респираторных звуков, а не для самостоятельной клинической диагностики без участия врача.

2. Медицинская основа дипломки

2.1. Почему вообще анализируют дыхание

Врач может слушать дыхание пациента с помощью стетоскопа. Этот процесс называется аускультацией.

Во время аускультации врач пытается уловить:

- нормальное дыхание;
- дополнительные шумы;
- характерные паттерны, связанные с сужением дыхательных путей, жидкостью, воспалением, бронхиальной обструкцией и другими нарушениями.

Проблема в том, что классическая аускультация:

- зависит от опыта врача;
- чувствительна к шуму;
- субъективна;
- трудно документируется количественно.

Именно поэтому возникла идея цифрового анализа дыхания: если записать звук и передать его модели, можно получить более стандартизированную и воспроизводимую оценку.

2.2. Что модель пытается распознать

В твоём проекте используется упрощенная, но практичная схема классов:

- 0 = normal

- 1 = crackle
- 2 = wheeze
- 3 = both

Normal

Это условный класс нормы: дыхание без выраженных патологических дополнительных шумов.

Crackle

Crackles — это короткие прерывистые звуки, похожие на потрескивание или щелчки. Они часто ассоциируются с:

- пневмонией;
- интерстициальными изменениями;
- застойными состояниями;
- фиброзом;
- другими состояниями, при которых нарушается механика воздушных путей и альвеол.

Wheeze

Wheezes — это более протяженные “музыкальные” свистящие звуки. Они часто возникают при:

- бронхиальной обструкции;
- астме;
- хронической обструктивной болезни легких;
- сужении дыхательных путей.

Both

Это смешанный класс: в одном сегменте присутствуют и crackles, и wheezes.

Этот класс сложен, потому что:

- он акустически неоднороден;
- встречается реже;
- его легче перепутать с соседними классами.

2.3. Почему это медицински сложно

В медицине один и тот же диагноз не всегда дает один и тот же звук. И наоборот: один и тот же тип звука может встречаться при разных заболеваниях.

То есть модель в твоём проекте учиться не “узнавать болезнь по паспорту”, а распознавать акустические феномены, которые потенциально связаны с патологией.

Это принципиальный момент для диплома и защиты.

Правильный тезис:

Модель классифицирует респираторные звуковые паттерны, а не ставит окончательный клинический диагноз.

3. Почему звук переводят в спектрограмму

3.1. Почему нельзя просто дать сети сырую волну

Аудиозапись — это последовательность амплитуд по времени. Теоретически модель можно обучать прямо на raw waveform, но для небольшой медицинской дипломной работы это сложнее:

- нужно больше данных;
- raw audio сложнее стабильно обучать;
- интерпретировать сложнее;
- на практике спектральные признаки часто работают надежнее как baseline.

Поэтому в проекте звук переводится в спектрограмму.

3.2. Что такое спектрограмма

Спектрограмма — это представление, где по одной оси идет время, по другой — частота, а яркость показывает энергию сигнала.

Идея простая:

- не просто “какой звук был”,
- а “какие частоты были активны и когда”.

Для дыхательных звуков это очень удобно, потому что:

- crackles выглядят как короткие локальные всплески;
- wheezes имеют более протяженные и устойчивые частотные структуры;
- модель может искать характерные паттерны уже не в “сырых колебаниях”, а в более структурированной картине.

3.3. Почему используется mel-шкала

Человек воспринимает частоты не линейно. Mel-шкала — это способ приблизить частотное представление к человеческому слуховому восприятию.

В проекте это полезно потому, что:

- mel-спектрограммы стали стандартом для аудиоклассификации;
- они хорошо работают с pretrained vision-моделями;
- их проще использовать как вход в CNN и AST.

3.4. Что такое log-mel

После вычисления спектра энергию часто переводят в логарифмическую шкалу.

Зачем:

- энергетические различия становятся более устойчивыми;
- слабые и сильные компоненты сигнала становятся лучше сопоставимы;
- модель получает более удобный диапазон значений.

4. Обработка сигнала в проекте

4.1. Частота дискретизации

Аудио хранится как последовательность отсчетов.

Частота дискретизации показывает, сколько отсчетов в секунду мы используем.

В проекте используются два режима:

- 22050 Hz для CNN-ветки;
- 16000 Hz для AST-ветки.

Почему это нормально:

- 22050 Hz достаточно для спектрограмм и классических аудиопризнаков;
- 16000 Hz часто используется в аудио-трансформерах и speech/audio pipelines;
- это компромисс между качеством и вычислительной стоимостью.

4.2. Нормализация по записи

В проекте используется instance normalization на уровне отдельной записи:

- вычитается среднее;
- делится на стандартное отклонение.

Зачем:

- разные записи сделаны разными устройствами;
- громкость и условия записи различаются;
- нормализация уменьшает доменное смещение, связанное с техникой записи, а не с патологией.

Что важно говорить:

Нормализация нужна не для “улучшения звука”, а для уменьшения технической вариативности между источниками данных.

4.3. Окна фиксированной длины

Нейросетям обычно удобно работать со входом одинакового размера. Поэтому длинные записи режутся или загружаются как окна фиксированной длины.

В проекте используется логика фиксированного окна, например 5 секунд.

Это дает:

- одинаковый размер входа;
- удобную батч-обработку;
- более стабильную работу CNN.

Почему это не идеально:

- реальные дыхательные события могут быть короче или длиннее;
- часть окна может содержать менее полезный контекст;
- но как baseline это хороший и практичный выбор.

5. Что такое глубокое обучение в контексте этой работы

5.1. Базовая идея

Глубокое обучение — это подход, при котором модель сама учится извлекать признаки из данных.

В классическом машинном обучении мы бы вручную придумывали:

- спектральные дескрипторы;
- статистики;
- handcrafted features.

В deep learning:

- модель получает вход;

- проходит через множество слоев;
- постепенно строит все более сложные признаки;
- в конце выдает предсказание класса.

5.2. Почему deep learning подходит здесь

Потому что респираторные звуки:

- сложны;
- неоднородны;
- имеют нелинейную структуру;
- зависят от времени и частоты одновременно.

Глубокие модели хорошо подходят для таких задач, потому что умеют:

- искать локальные паттерны;
- комбинировать их в более сложные структуры;
- учиться на спектрально-временных представлениях.

6. CNN: теория с нуля

6.1. Что такое CNN

CNN — это сверточная нейронная сеть.

Ее главная идея:

вместо того чтобы сразу связывать каждый вход со всеми нейронами, модель ищет локальные паттерны с помощью маленьких фильтров.

Для изображений это:

- края;
- текстуры;
- формы.

Для спектрограмм это:

- короткие всплески;
- полосы по частоте;
- устойчивые паттерны по времени;
- локальные комбинации акустических признаков.

6.2. Что делает свертка

Свертка берет маленькое окно, например 3x3, и “скользит” им по входу.

На каждом шаге фильтр вычисляет, насколько сильно в этом месте присутствует определенный шаблон.

Если говорить совсем просто:

- фильтр как будто спрашивает:

“похоже ли это место на тот паттерн, который я ищу?”

Когда фильтров много, модель учится находить разные типы паттернов.

6.3. Почему это полезно для дыхательных спектрограмм

Потому что crackles и wheezes проявляются как локальные структуры:

- crackles более короткие и импульсные;
- wheezes более протяженные по времени;
- mixed class сочетает несколько паттернов.

CNN умеет ловить именно такие локальные особенности.

6.4. Что такое pooling

Pooling уменьшает размер представления и делает модель менее чувствительной к мелким сдвигам.

Идея:

- если паттерн немного сдвинулся по времени или частоте,
- модель все равно должна его узнавать.

6.5. Что такое receptive field

Receptive field — это область входа, которую “видит” нейрон на более глубоком уровне сети.

В начале сеть видит очень локальные детали. Чем глубже слой, тем более широкий контекст он учитывает.

Для дыхательных спектрограмм это важно, потому что:

- сначала сеть ловит короткие локальные паттерны;
- потом собирает их в более крупные звуковые структуры.

7. ResNet50: теория и смысл

7.1. Почему обычные глубокие CNN стали проблемой

Когда сети стали глубже, оказалось, что обучать их трудно:

- градиенты затухают;
- оптимизация усложняется;
- увеличение глубины не всегда улучшает результат.

7.2. Что придумал ResNet

ResNet добавил residual connections, то есть shortcut-связи.

Идея такая:

вместо того чтобы каждый блок учился строить полное новое преобразование, он учится строить поправку к уже существующему представлению.

Формально:

выход блока = вход + изученная поправка

Это сильно облегчает обучение глубоких сетей.

7.3. Почему ResNet50 все еще актуален

Да, архитектура не новая. Но для дипломки это очень разумный baseline, потому что:

- она стабильна;
- хорошо изучена;
- есть pretrained weights;
- легко интерпретируется;
- очень часто используется в литературе как reference model.

7.4. Как объяснить выбор ResNet на защите

Короткий хороший ответ:

ResNet50 используется как сильная и проверенная baseline-архитектура. Ее роль не в том, чтобы быть самой новой моделью, а в том, чтобы дать надежную отправную точку для честного сравнения с более современными подходами.

8. EfficientNet-B3: теория и смысл

8.1. В чем идея EfficientNet

EfficientNet пытается масштабировать сеть не хаотично, а сбалансированно.

Обычные подходы раньше делали что-то одно:

- либо сеть глубже;
- либо шире;
- либо вход крупнее.

EfficientNet предлагает compound scaling:

- глубина;
- ширина;
- размер входа

увеличиваются согласованно.

8.2. Почему это может помочь

Идея в том, что архитектура использует параметры более эффективно.

То есть модель может:

- давать хорошее качество;
- быть компактнее;
- лучше использовать вычисления.

8.3. Что значит V3

V3 — это один из вариантов семейства EfficientNet. Он сильнее, чем совсем маленькие версии, но еще не слишком тяжелый.

Поэтому для дипломки это разумный компромисс:

- достаточно современная CNN;
- не слишком гигантская;
- подходит для baseline-сравнения с ResNet50.

8.4. Что важно помнить

То, что EfficientNet современнее, не гарантирует, что он будет лучше на этой конкретной медицинской задаче.

Это и есть важный научный вопрос:

Дает ли более современная CNN реальный выигрыш на дыхательных спектрограммах?

9. AST: теория и смысл

9.1. Что такое AST

AST — это Audio Spectrogram Transformer.

Он берет спектрограмму и обрабатывает ее не как классическая CNN, а как последовательность патчей с механизмом внимания.

9.2. Что такое внимание

Self-attention позволяет каждому элементу представления учитывать другие элементы.

Идея:

- не только локальный контекст;
- но и более дальние связи по времени и частоте.

Для дыхательных звуков это потенциально полезно, потому что:

- важен не только один локальный всплеск;
- иногда важна структура паттерна на более длинном участке.

9.3. Почему AST вообще нужен в дипломе

Потому что без него работа была бы просто сравнением двух CNN.

AST поднимает диплом на уровень более интересного исследовательского вопроса:

лучше ли трансформерная архитектура для анализа респираторных спектрограмм, чем сверточные сети?

9.4. Честная оговорка

AST не гарантированно выигрывает.

Почему:

- он тяжелее;
- может требовать больше данных;
- чувствителен к настройке;
- на небольших медицинских датасетах иногда проигрывает более стабильным CNN.

Именно это делает сравнение научно содержательным.

10. Что такое обучение модели

10.1. Forward pass

Модель получает вход и выдает логиты по классам.

Например:

- normal: 2.1
- crackle: 0.7
- wheeze: 1.9
- both: -0.3

Чем выше логит, тем сильнее модель “склоняется” к классу.

10.2. Loss

Потом считается функция потерь, которая показывает, насколько предсказание плохо.

В твоём проекте это CrossEntropyLoss.

Почему она подходит:

- задача многоклассовая;
- модель выдает один класс из четырех;
- это стандартная и корректная функция потерь для такой постановки.

10.3. Backward pass

После этого считается градиент ошибки по параметрам сети.

Простая идея:

- модель ошиблась;
- нужно понять, как изменить веса, чтобы ошибаться меньше.

10.4. Optimizer

Optimizer обновляет веса сети.

В текущем baseline используется Adam.

Почему это нормально:

- Adam стабилен;
- быстро сходится;

- хорошо подходит для первого baseline.

11. Почему нужен patient-level split

Это один из самых важных методологических моментов.

Если один и тот же пациент попадет и в train, и в validation, модель может запоминать:

- особенности конкретной записи;
- конкретный тембр дыхания;
- особенности устройства или позиции записи.

Тогда качество будет искусственно завышено.

Поэтому разбиение делается по пациентам, а не по отдельным сегментам.

Это надо уметь очень уверенно объяснить:

Patient-level split используется для предотвращения data leakage и получения реалистичной оценки обобщающей способности модели.

12. Почему нужен weighted sampler

В твоих данных классы несбалансированы.

Это значит:

- normal обычно встречается чаще;
- both реже;
- модель легко может начать “любить” частые классы.

WeightedRandomSampler помогает чаще показывать редкие классы при обучении.

Важно:

- в train это полезно;
- в validation искусственно менять распределение нельзя, иначе оценка станет нечестной.

13. Метрики: что они означают

13.1. Accuracy

Accuracy — доля правильных ответов.

Это простая метрика, но для несбалансированных данных она ограничена.

Если класс normal слишком частый, модель может выглядеть “хорошей” по ассигасу, даже если плохо распознает редкие патологии.

13.2. Precision

Precision отвечает:

если модель предсказала этот класс, как часто она была права?

13.3. Recall

Recall отвечает:

из всех истинных объектов этого класса сколько модель нашла?

В медицинских задачах recall часто особенно важен, потому что пропуск патологии может быть опаснее ложной тревоги.

13.4. F1-score

F1 — это баланс между precision и recall.

Если модель:

- часто ошибается ложными срабатываниями;
- или часто пропускает истинные случаи,

F1 будет это наказывать.

13.5. Macro F1

Macro F1 считает F1 отдельно по каждому классу, а потом усредняет их равноправно.

Это очень важная метрика для твоего проекта, потому что:

- классы несбалансированы;
- модель не должна хорошо работать только на normal;
- нам важно, как она ведет себя и на редких классах.

Если ассигасу заметно выше макро F1, это часто говорит о том, что редкие классы страдают.

13.6. Confusion matrix

Confusion matrix показывает:

- какие истинные классы;
- во что именно их предсказывает модель.

Это одна из самых информативных таблиц в дипломе.

Она отвечает на вопросы:

- путает ли модель crackle с wheeze;
- часто ли mixed class проваливается в соседние классы;
- не уходит ли модель массово в normal.

13.7. Calibration и ECE

Калибровка отвечает на вопрос:

можно ли доверять вероятностям модели?

Если модель говорит “я уверена на 90%”, это должно быть похоже на реальное качество.

ECE — одна из метрик калибровки.

Для медицинской тематики это важно, потому что уверенность модели сама по себе имеет практическую ценность.

14. Что такое переобучение

Переобучение — это ситуация, когда модель слишком хорошо запоминает train-набор, но не так хорошо работает на новых данных.

Типичный признак:

- train accuracy растёт быстро;
- train loss падает быстро;
- val accuracy растёт слабо или перестаёт расти;
- val loss начинает ухудшаться.

Это именно то, что у тебя уже начал показывать ResNet50 baseline.

Правильный вывод:

baseline рабочий, но текущая конфигурация демонстрирует признаки ограниченной обобщающей способности.

15. Что такое overconfidence

Иногда validation accuracy ещё растёт, но validation loss тоже растёт.

Это значит:

- модель угадывает немного больше примеров;
- но на ошибочных примерах становится слишком уверенной.

В медицинском проекте это важный warning:

не просто “ошибка”, а “самоуверенная ошибка”.

16. Почему важно сравнивать не только финальную эпоху

Лучшая модель не всегда находится на последней эпохе.

Поэтому важно отслеживать:

- best epoch
- best val loss

И сохранять лучший checkpoint именно по validation-критерию.

Это нужно и для честного сравнения моделей, и для дальнейшего тестирования на unseen datasets.

17. Как читать baseline-результаты в твоём проекте

Предположим:

- ResNet50 имеет чуть лучшую val_acc;
- EfficientNet-B3 имеет чуть лучший val_loss;
- macro F1 отличается;
- confusion matrix показывает разные типы ошибок.

Тогда научный вывод строится не по одной цифре, а по совокупности:

1. качество классификации;
2. баланс между классами;
3. динамика переобучения;
4. устойчивость validation loss;
5. типы ошибок.

18. Cross-domain evaluation

Почему вообще нужны BRACETS и SPRSound?

Потому что модель может работать хорошо “дома”, но плохо переноситься на другие источники.

Cross-domain evaluation проверяет:

- насколько модель зависит от конкретного датасета;
- умеет ли она переносить знания на другие записи;
- не переучилась ли она на артефакты конкретного домена.

Для сильной дипломки это одна из самых важных частей.

19. Explainability

19.1. Зачем нужен Grad-CAM

Grad-CAM позволяет показать, какие области входа были важны для решения модели.

Для спектрограмм это особенно полезно:

- можно визуально показать, где модель “смотрела”;
- это помогает анализировать ошибки;
- это сильный аргумент на защите.

19.2. Ограничения Grad-CAM

Важно честно говорить:

- это не доказательство истинности решения;
- это эвристическое объяснение;
- его нельзя воспринимать как клиническое основание само по себе.

20. Uncertainty

В медицине важно не только предсказать класс, но и понимать, насколько модель уверена.

Для этого можно использовать:

- MC Dropout
- calibration
- анализ уверенных и неуверенных случаев

Практический смысл:

если модель не уверена, это уже само по себе полезный сигнал.

21. Как строится вся дипломка как исследование

21.1. Этап 1. Data pipeline

Нужно:

- собрать датасеты;
- привести их к единому формату;
- нормализовать;
- проверить разметку;
- сделать patient-level split.

21.2. Этап 2. CNN baselines

Нужно:

- обучить ResNet50;
- обучить EfficientNet-B3;
- сравнить метрики;
- посмотреть переобучение;
- проанализировать confusion matrix.

21.3. Этап 3. Transformer baseline

Нужно:

- добавить AST;
- сравнить его с CNN;
- посмотреть, есть ли реальное преимущество.

21.4. Этап 4. Robustness и science part

Нужно:

- провести unseen evaluation;
- провести ablation study;
- оценить calibration.

21.5. Этап 5. Explainability и uncertainty

Нужно:

- сделать Grad-CAM;
- сделать uncertainty examples;
- показать это в дипломе и demo.

21.6. Этап 6. Demo

Нужно:

- создать интерфейс;
- подавать .wav;
- возвращать результат, confidence и визуализацию.

22. Как это раскладывается по главам диплома

Глава 1. Introduction

Здесь ты объясняешь:

- почему задача важна;
- почему аускультация сложна;
- почему AI может быть полезен;
- что именно ты предлагаешь.

Глава 2. Related Work

Здесь надо показать:

- что уже делали до тебя;
- какие архитектуры использовали;
- какие пробелы остались;
- чем твоя работа отличается.

Глава 3. Methodology

Здесь описывается:

- датасеты;
- unified labels;
- preprocessing;
- spectrogram pipeline;
- модели;

- split;
- метрики;
- training procedure.

Глава 4. Experiments & Results

Здесь будут:

- baseline-сравнения;
- AST comparison;
- confusion matrices;
- cross-domain evaluation;
- explainability;
- ablations.

Глава 5. Conclusion

Здесь нужно ответить:

- что удалось показать;
- где сильные стороны системы;
- какие ограничения;
- что делать дальше.

23. Как отвечать на типичные вопросы комиссии

Почему вы выбрали спектрограммы?

Потому что спектрограмма переводит сложный аудиосигнал в частотно-временное представление, где патологические респираторные паттерны становятся более структурированными и лучше подходят для глубоких моделей, особенно CNN и audio transformers.

Почему ResNet, если это старая модель?

Потому что для дипломной работы важен не только самый новый подход, но и надежный baseline. ResNet50 дает стабильную и хорошо изученную отправную точку для честного сравнения с более современными архитектурами.

Почему patient-level split обязателен?

Потому что иначе возникнет data leakage: модель может запомнить особенности конкретного пациента или записи, а не патологический паттерн.

Почему одной accuracy недостаточно?

Потому что классы несбалансированы, а медицинская задача требует более честной оценки качества на всех классах. Поэтому используется macro F1 и confusion matrix.

Почему высокий train accuracy не означает хорошую модель?

Потому что модель может переобучиться и плохо обобщать на новых пациентах. Поэтому решающими являются validation-метрики и поведение на unseen data.

Что значит рост val loss при росте val accuracy?

Это может означать, что модель стала чуть чаще угадывать, но на ошибках стала слишком самоуверенной. В медицинском контексте это важный сигнал риска.

24. Практическая карта обучения для тебя

Если ты хочешь действительно “понять всю дипломку”, тебе полезно учиться именно в таком порядке:

1. Медицинский смысл классов.
2. Что такое спектрограмма и mel-scale.
3. Как работает CNN.
4. Как работает ResNet.
5. Как работает EfficientNet.
6. Что такое transformer и attention.
7. Что такое loss, optimizer, overfitting.
8. Что такое accuracy, F1, macro F1, confusion matrix.
9. Что такое calibration и uncertainty.
10. Как это переводится в научные выводы.

Это правильный путь: от смысла задачи к архитектурам, а не наоборот.

25. Что уже обязательно надо понимать по текущему проекту

На текущем этапе ты уже должен уметь объяснить:

- почему в проекте несколько датасетов;
- зачем unified labels;
- почему нужен patient-level split;
- почему используется spectrogram pipeline;

- чем ResNet50 отличается от EfficientNet-B3;
- почему accuracy не равна качеству всей модели;
- почему macro F1 важен;
- что значит overfitting;
- почему best checkpoint может быть не на последней эпохе;
- зачем позже нужны AST, Grad-CAM и MC Dropout.

26. Что станет ядром научного результата дипломки

Скорее всего, твой настоящий научный вклад будет лежать не в одной точке, а в сочетании нескольких вещей:

1. Честное сравнение CNN и Transformer на respiratory acoustics.
2. Анализ generalization и overfitting на разнородных датасетах.
3. Оценка поведения моделей на редких классах.
4. Cross-domain evaluation на unseen datasets.
5. Explainability и uncertainty как практическая надстройка.

Именно это делает дипломку сильной.

27. Что делать после чтения этого документа

После чтения этого файла ты не должен пытаться “запомнить все подряд”. Твой рабочий режим должен быть такой:

1. Читаешь раздел.
2. Смотришь, как он связан с твоим текущим кодом.
3. Пытаешься объяснить это своими словами.
4. Записываешь короткую версию для главы диплома.
5. Возвращаешься к экспериментам.

Именно так теория перестает быть абстракцией и превращается в часть дипломной работы.

28. Финальный смысл всего проекта

Самое главное:

ты строишь не “скрипт для классификации”, а исследовательскую систему, которая должна ответить на вопрос:

Насколько глубокие модели способны распознавать патологические респираторные звуковые паттерны по спектрограммам, какие архитектуры работают лучше, насколько их выводы устойчивы, и можно ли сделать из этого основу для интерпретируемого медицинского прототипа?

Если ты держишь этот вопрос в голове, все остальные части дипломки складываются в одну логическую линию.

29. Что читать дальше: проверенные материалы и ссылки

Ниже не “случайный список из интернета”, а опорные материалы, которые действительно полезны именно для этой дипломки.

29.1. Респираторные звуки и ICBHI

1. ICBHI respiratory sound database paper
A Respiratory Sound Database for the Development of Automated Classification DOI / page: https://www.researchgate.net/publication/321135914_A_Respiratory_Sound_Database_for_the_Development_of_Automated_Classification
2. Современный обзор по ICBHI и respiratory sound analysis
Advances and Challenges in Respiratory Sound Analysis: A Technique Review Based on the ICBHI2017 Database <https://www.mdpi.com/2079-9292/14/14/2794>

29.2. Базовая теория CNN и компьютерного зрения

3. ResNet paper
Deep Residual Learning for Image Recognition arXiv: <https://arxiv.org/abs/1512.03385>
4. Практическая логика DataLoader и Dataset в PyTorch
Datasets & DataLoaders — PyTorch Tutorials
https://docs.pytorch.org/tutorials/beginner/basics/data_tutorial.html
5. Writing Custom Datasets, DataLoaders and Transforms
PyTorch tutorial https://docs.pytorch.org/tutorials/beginner/data_loading_tutorial.html

29.3. Более современная CNN-архитектура

6. EfficientNet paper

29.4. Audio Transformers

7. AST paper

AST: Audio Spectrogram Transformer arXiv: <https://arxiv.org/abs/2104.01778>

8. SSAST paper

SSAST: Self-Supervised Audio Spectrogram Transformer arXiv: <https://arxiv.org/abs/2110.09784>

29.5. Аудиообработка и спектрограммы

9. librosa mel spectrogram documentation

<https://librosa.org/doc/latest/generated/librosa.feature.melspectrogram.html>

10. PyTorch Data API

<https://docs.pytorch.org/docs/stable/data.html>

29.6. Метрики

11. F1 score documentation

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html

12. Confusion matrix documentation

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html

29.7. Как читать эти материалы правильно

Полезная стратегия:

1. Сначала читать этот документ.
2. Потом брать один внешний источник.
3. После чтения объяснять его своими словами.
4. Сразу связывать с твоим кодом и текущими экспериментами.

Если читать все подряд без привязки к проекту, знания быстро расплывутся.

30. Как использовать этот файл как учебник

Вот рабочий режим, который я тебе советую.

Режим 1. Погружение в теорию

Читаешь один крупный раздел:

- например только CNN;
- или только метрики;
- или только медицинскую часть.

Потом пытаешься ответить сам себе:

- что это?
- зачем это нужно?
- как это проявляется именно в моем проекте?

Режим 2. Привязка к коду

После теории смотришь:

- где это находится в src/;
- как это отражено в scripts/;
- как это проявляется в текущих метриках и графиках.

Режим 3. Подготовка к защите

После чтения каждого раздела нужно уметь дать:

1. короткий ответ на 20 секунд;
2. нормальный академический ответ на 1–2 минуты;
3. технический ответ, если комиссия начнет углубляться.

Именно тогда теория станет частью твоей защиты, а не просто чтением.

31. Расширенная карта источников: что читать, зачем и в каком порядке

Ниже уже не просто список ссылок, а структурированная карта внешних материалов. Ее задача не в том, чтобы ты прочитал все подряд, а в том, чтобы у тебя был путь:

1. сначала понять базовую идею;
2. потом прочитать опорную статью;
3. затем связать ее с твоим кодом и текущими экспериментами;
4. только после этого углубляться дальше.

31.1. Медицинская база по дыхательным шумам

1. MSD Manual: Wheezing

Зачем читать: чтобы понять клинический смысл wheeze не по ML-статьям, а по нормальному медицинскому источнику. <https://www.msmanuals.com/professional/pulmonary-disorders/symptoms-of-pulmonary-disorders/wheezing>

2. MSD Manual: Evaluation of the Patient With Pulmonary Issues

Зачем читать: чтобы лучше понять, что такое crackles, wheezes и adventitious sounds в клиническом языке. <https://www.msmanuals.com/professional/pulmonary-disorders/approach-to-the-pulmonary-patient/evaluation-of-the-pulmonary-patient>

3. Review: Advances and Challenges in Respiratory Sound Analysis

Зачем читать: это один из самых полезных обзоров именно по ICBHI и respiratory sound analysis. <https://www.mdpi.com/2079-9292/14/14/2794>

31.2. Данные и сама задача respiratory sound analysis

4. ICBHI 2017 database paper

Зачем читать: это исходная работа, объясняющая, откуда берется один из главных датасетов твоей дипломки. https://www.researchgate.net/publication/321135914_A_Respiratory_Sound_Database_for_the_Development_of_Automated_Classification

5. Automatic Classification of Adventitious Respiratory Sounds: A (Un)Solved Problem?

Зачем читать: очень полезная статья, чтобы увидеть, насколько задача до сих пор остается сложной. <https://pmc.ncbi.nlm.nih.gov/articles/PMC7795327/>

6. Automated Lung Sound Classification Using a Hybrid CNN-LSTM Network and Focal Loss Function

Зачем читать: хороший пример прикладной работы именно на ICBHI с понятной структурой methodology. <https://pmc.ncbi.nlm.nih.gov/articles/PMC8838187/>

31.3. База по CNN

7. ResNet paper

Deep Residual Learning for Image Recognition Это обязательная статья. Ее нужно знать не “по названию”, а по сути. <https://arxiv.org/abs/1512.03385>

8. PyTorch Tutorial: Datasets & DataLoaders

Зачем читать: чтобы понимать не только модель, но и правильную организацию data pipeline. https://docs.pytorch.org/tutorials/beginner/basics/data_tutorial.html

9. PyTorch Docs: torch.utils.data

Зачем читать: это уже более технический уровень про DataLoader, samplers, batching и workers.
<https://docs.pytorch.org/docs/stable/data.html>

31.4. Более современная CNN-ветка

10. EfficientNet paper

EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks Обязателен для понимания, почему EfficientNet считается более современной CNN-семьей. <https://arxiv.org/abs/1905.11946>

11. Google Research page for EfficientNet

Зачем читать: краткая официальная страница, удобна как быстрый reference. <https://research.google/pubs/efficientnet-rethinking-model-scaling-for-convolutional-neural-networks/>

31.5. Трансформеры для аудио

12. AST paper

AST: Audio Spectrogram Transformer Ключевая статья для трансформерной части дипломки.
<https://arxiv.org/abs/2104.01778>

13. SSAST paper

Self-Supervised Audio Spectrogram Transformer Полезен, если пойдешь глубже в transformer audio literature. <https://arxiv.org/abs/2110.09784>

31.6. Обработка аудио и спектрограммы

14. librosa: melspectrogram

Зачем читать: это практически прямая документационная опора для твоего preprocessing pipeline.
<https://librosa.org/doc/latest/generated/librosa.feature.melspectrogram.html>

15. librosa: mel frequencies

Зачем читать: чтобы глубже понять, как устроена mel-шкала, а не просто использовать ее как готовую функцию. https://librosa.org/doc/latest/generated/librosa.mel_frequencies.html

31.7. Метрики и интерпретация качества

16. scikit-learn: f1_score

Зачем читать: чтобы уверенно объяснять, почему макро F1 важнее одной accuracy при дисбалансе классов. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html

17. scikit-learn: confusion_matrix

Зачем читать: чтобы грамотно интерпретировать, какие классы с какими путаются.
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html

31.8. Explainability, robustness, calibration

18. Grad-CAM paper

Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization Нужен для explainability части и для будущего demo. <https://arxiv.org/abs/1610.02391>

19. On Calibration of Modern Neural Networks

Это базовая статья, если будешь объяснять calibration, confidence и ECE. <https://arxiv.org/abs/1706.04599>

20. Dropout as a Bayesian Approximation

Полезно для будущего блока uncertainty / MC Dropout. <https://arxiv.org/abs/1506.02142>

32. Как изучать всю дипломку как книгу, а не как набор файлов

Ниже самый практичный путь погружения.

32.1. Уровень 1. Быстрое понимание всей конструкции

Сначала нужно понимать не детали, а весь замысел:

1. что такое respiratory sound classification;
2. почему используются спектрограммы;
3. зачем сравниваются CNN и Transformer;
4. почему macro F1 важнее одной accuracy;
5. почему это исследовательский прототип, а не клиническая машина для постановки диагноза.

Это тот минимум, без которого дальше все остальное будет распадаться на куски.

32.2. Уровень 2. Понимание data pipeline

На этом уровне ты должен уметь объяснить:

- откуда берутся данные;
- что делает parser;
- зачем нужен patient-level split;
- как audio превращается в mel spectrogram;
- почему вход модели имеет фиксированную длину.

Если этот слой не понят, модельная часть тоже будет казаться “магией”.

32.3. Уровень 3. Понимание CNN

Здесь нужно уметь отвечать:

- что такое свертка;
- что такое фильтр;
- что такое pooling;
- что такое receptive field;
- зачем residual connections в ResNet;
- чем EfficientNet концептуально отличается от ResNet.

32.4. Уровень 4. Понимание обучения

Здесь уже нужно уверенно владеть:

- forward pass;
- logits;
- softmax;
- cross-entropy loss;
- backward pass;
- optimizer;
- overfitting.

32.5. Уровень 5. Понимание оценки качества

На этом уровне ты уже не просто “смотришь на цифры”, а интерпретируешь:

- accuracy;
- macro F1;
- confusion matrix;
- best epoch;
- val loss versus val accuracy;
- calibration and confidence.

32.6. Уровень 6. Научный уровень

Финальный уровень понимания:

- почему одна модель лучше другой;
- почему модель может переобучаться;

- почему редкие классы труднее;
 - почему external validation критически важна;
 - как explainability и uncertainty усиливают ценность работы.
-

33. Маршрут погружения на 14 дней

Если хочешь не просто читать, а реально вникнуть, вот рабочая траектория.

День 1-2

- Прочитать разделы 1–5 этого документа.
- Понять общую идею дипломки.
- Отдельно выписать своими словами разницу между “патологическим звуком” и “диагнозом”.

День 3-4

- Прочитать разделы про спектрограммы и preprocessing.
- Посмотреть `src/data/preprocessing.py`.
- Связать теорию с реальным кодом.

День 5-6

- Прочитать разделы про CNN и ResNet.
- Потом открыть `src/models/cnn_baseline.py`.
- Понять, что именно ты называешь baseline-моделью.

День 7-8

- Прочитать разделы про EfficientNet и AST.
- Сформулировать, чем CNN и Transformer отличаются именно на дыхательных спектрограммах.

День 9-10

- Прочитать разделы про loss, optimizer, обучение и overfitting.
- Посмотреть `src/train.py`.
- Понять каждый этап training loop.

День 11-12

- Прочитать разделы про метрики.
- Разобрать свои текущие результаты ResNet50.

- Научиться объяснять, почему `val_acc` и `macro F1` говорят разное.

День 13-14

- Пройти разделы про `explainability`, `uncertainty` и финальную структуру диплома.
- После этого попробовать устно объяснить весь `pipeline` от `.wav` до `confusion matrix` без подсказок.

34. Как понять, что ты уже действительно владеешь дипломкой

Ниже простой `self-check`.

Ты действительно погрузился в дипломку, если умеешь без чтения файла ответить:

1. Почему мы используем спектрограммы, а не `raw waveform`?
2. Почему `ResNet50` до сих пор оправдан как `baseline`?
3. Почему `EfficientNet-B3` считается более современной `CNN`?
4. Почему `macro F1` важнее одной `accuracy`?
5. Почему `best epoch` может быть ранним, даже если `final train accuracy` очень высокая?
6. Почему `confusion matrix` особенно важна для класса `both`?
7. Почему `patient-level split` обязателен?
8. Почему модель не ставит диагноз напрямую?
9. Зачем нужен `Grad-CAM`?
10. Зачем нужен `MC Dropout` или другой `uncertainty`-механизм?

Если ты можешь нормально ответить на эти вопросы, значит у тебя уже не просто “есть код”, а есть настоящая интеллектуальная опора для защиты.